

思维点和分歧度是模型自我持续学习的依据

Thought Points and Divergence as the Basis for
Model Self-Continuous Learning

Zhenglong Qiu*

https://github.com/QZL2004qzl/DATP_DAM

摘要

当前深度学习模型面临两大核心瓶颈：其一，预训练完成后模型参数被固定，无法在部署阶段进行实时、可持续的自我学习——面对新知识时，传统的微调（Fine-tuning）和检索增强生成（RAG）等上下文嵌入方法虽能部分缓解，但微调仍面临灾难性遗忘风险且计算代价较高，上下文嵌入则受限于窗口长度且不产生持久的参数化知识增长；其二，基于 Transformer 的自注意力机制具有 $O(n^2)$ 的时间复杂度与 $O(n)$ 的显存占用，随着序列长度增长推理成本呈平方级膨胀，严重制约了模型在长文本和资源受限场景中的应用。针对上述双重挑战，本文从人类认知科学中的双系统理论（Dual-Process Theory）出发，提出了分聚思维点网络（Divergent-Aggregate Thought-Point Network, DATP）与分歧聚合机制（Divergence Aggregation Mechanism, DAM）。DATP 通过解耦的审判官网络实现对模型认知边界的感知，并在非参数空间中引入具备空间聚合与生物遗忘特征的动态思维点池，赋予模型在冻结基座参数前提下的流式持续自我学习能力。DAM 则以分歧度替代传统的相似度量，将历史时序特征压缩凝聚为动态演进的思维点，以 $O(nd)$ 时间复杂度，并将推理显存从标准注意力的 $O(nd)$ （随序列长度线性增长）降至与序列长度 n 无关的 $O(d)$ 恒定水平（仅需维护两个 d 维累积向量，不随生成步数增长），实现了对注意力机制的高效替代。本文从理论上论证了思维点与分歧度概念的科学与可行性，并从线性记忆锚定、隐式分歧度门控和演化动力学三个维度构建了完整的数学框架。需要指出的是，本文的实验验证目前限于小规模回归和语言建模任务，DATP 在大规模语言模型上的部署和 DAM 在更多基准上的全面验证是后续工作的重点。在 WikiText-103 数据集上的预训练实验表明，DAM 架构在 84MB 参数量、1024 序列长度条件下达到 20.69 的困惑度；在五个标准回归数据集上的 DATP 实验表明，全演化模式下的思维点数量相比无演化模式按总数加权计算减少约 72%，推理延迟控制在每样本 0.08–0.63 毫秒，

*E-mail: 2922490672@qq.com

而回归性能保持稳定。本文的工作为解决模型持续自我学习问题提供了新的理论依据与工程路径。

关键词：思维点；分歧度；持续学习；注意力机制替代；分聚思维点网络；分歧聚合机制；演化动力学；灾难性遗忘

1 引言

1.1 深度学习模型的核心困境

近年来，大规模深度学习模型在自然语言处理、计算机视觉和多模态理解等领域取得了突破性进展。以 GPT 系列、Claude 系列和 DeepSeek 系列为代表的大语言模型（Large Language Models, LLMs）展现了令人瞩目的涌现能力，在机器翻译、文本生成、代码编写和复杂推理等任务上达到了接近甚至超越人类专家的水平。然而，这些辉煌成就的背后，隐藏着两个根本性的、尚未被充分解决的架构性瓶颈。

第一个瓶颈是模型无法实现部署后的自我持续学习。当前主流的深度学习范式遵循“预训练-微调-部署”的三阶段流程。模型一旦完成预训练并部署到生产环境，其参数便处于完全冻结状态。这意味着：（1）模型在推理阶段接触到的任何新知识、新模式或新概念都无法被吸收和内化，只能在下一次昂贵的全量或部分重训练中才能被纳入参数空间；（2）模型在面对分布外（Out-of-Distribution, OOD）样本时，缺乏自适应的即时纠错能力，只能持续输出错误预测；（3）模型的知识始终停留在预训练数据的截止时间点，无法像生物智能体那样通过与环境的持续交互实现知识的增量积累与实时进化。

这种“训练-冻结-部署”的范式与生物智能的学习方式形成了鲜明对比。人类大脑能够在日常生活中不断吸收新信息、修正错误认知、遗忘无效知识，而无需回到一个离线阶段进行“全脑重训练”。这种持续、流式的自我学习能力，是通向通用人工智能（Artificial General Intelligence, AGI）的关键要素之一。然而，实现持续学习面临着一个根本性的技术难题——灾难性遗忘（Catastrophic Forgetting）[20]：当神经网络在新数据上进行梯度更新时，旧知识所对应的权重配置会不可逆地被覆盖，导致模型在新任务上表现提升的同时，旧任务上的性能急剧退化。

第二个瓶颈是 Transformer 自注意力机制的计算与存储复杂度呈平方级增长。Transformer 架构自 Vaswani 等人在 2017 年提出以来 [1]，已经成为深度学习领域的事实标准。其核心创新——缩放点积自注意力机制（Scaled Dot-Product Self-Attention）——通过计算序列中每一对 Token 之间的相似度，实现了全局上下文的高效建模。然而，这种全连接式的两两交互机制带来了 $O(n^2)$ 的时间复杂度和 $O(n)$ 的键值（Key-Value, KV）缓存空间复杂度，其中 n 为输入序列长度。这意味着：（1）当序列长度从 1K 增长到 32K 时，单层注意力的计算量增长了约 1024 倍；（2）在自回归解码过

程中，每个新生成的 Token 都需要与所有历史 Token 进行注意力计算，KV 缓存的大小随生成步数线性增长；(3) 在资源受限的边缘设备和移动端场景中，这种复杂度增长使得长文本推理实际上不可行。

更为根本的是，这两个瓶颈并非彼此孤立，而是紧密交织在一起的。在标准的 Transformer 架构下，模型若想实现持续学习，就必须对注意力层的参数进行更新，而这不仅会触发灾难性遗忘，还会因注意力机制的平方级复杂度使得每次自适应更新的计算代价变得不可接受。因此，要实现真正的模型自我持续学习，必须同时解决“学什么、怎么学、在哪学”三个层面上的问题，而这三个问题的答案分别指向：知识表征的形式（思维点）、更新判断的依据（分歧度）以及高效的底层计算算子（DAM 机制）。

1.2 认知科学的启示：双系统理论

本文提出的方法论体系，其核心灵感来源于认知科学中的双系统理论（Dual-Process Theory）。该理论由诺贝尔经济学奖得主 Daniel Kahneman 在其著作《思考，快与慢》（*Thinking, Fast and Slow*, 2011）[16] 中系统阐述，并由 Stanovich 和 West 在 2000 年的工作中奠定了理论框架 [17]。双系统理论将人类的认知过程划分为两个在功能、速度和资源消耗上截然不同的子系统：

- **系统 1（快思考）**：自动化的、直觉式的、几乎不需消耗认知资源的快速反应系统。它依据过往经验和模式匹配对大部分常规、熟悉的情境做出即时判断。系统 1 的处理是并行的、无意识的，能够在毫秒级别内完成。
- **系统 2（慢思考）**：受控的、分析式的、需要消耗大量认知资源的深度推理系统。它仅在系统 1 遇到认知冲突、不确定性或高度复杂的难题时被激活，通过逻辑推理、因果分析和假设检验进行审慎的判断。系统 2 的处理是串行的、有意识的，需要主观努力。

这一认知框架在人工智能领域的映射日益受到关注。Nye 等人（2021）[18] 明确指出，当前的大语言模型本质上是“仅有系统 1”的推理器——它们在海量训练数据上进行快速的模式匹配和统计关联，但在面对需要多步逻辑验证、约束满足或反事实推理的任务时，往往表现出系统性的偏差和幻觉。近年来，研究者开始探索将双系统理论嵌入 AI 架构的路径，包括神经符号推理（Neuro-Symbolic Reasoning）系统、SOFAI（Slow and Fast AI）多智能体框架以及使用思维链（Chain-of-Thought）提示来模拟系统 2 的推理过程。

本文的工作在此基础上更进一步：我们不仅将双系统理论作为一种行为层面的启示，而是将其直接编码到神经网络的基础架构设计中。在 DATP 框架下，冻结参数的通用基座网络充当了直觉式的系统 1，而动态演化的思维点池则扮演了需要时被激活的系统 2 角色。两者之间的切换由一个解耦的审判官网络（认知元监控器）根据分歧

度度量来决定，从而实现了**按需计算**（Compute-on-Demand）的认知资源分配策略。

1.3 本文的主要贡献

本文的主要贡献可以概括为以下四个方面：

1. **概念创新**：首次提出了“思维点”和“分歧度”的数学化定义，将人类认知科学中的双系统理论、记忆压缩和认知冲突检测等概念系统地转译为深度学习的基础计算原语，为模型自我持续学习提供了新的理论视角。
2. **架构创新**：设计了分聚思维点网络（DATP），通过通用基座网络、解耦审判官和动态思维点池的三元架构，实现了模型在不修改基座参数前提下的流式持续学习。提出了包含空间聚合和生物遗忘的演化动力学机制，保证了思维点池的泛化能力与有界性。
3. **算子创新**：提出了分歧聚合机制（DAM），以分歧度替代相似度作为信息交互的核心度量，将自注意力的 $O(n^2)$ 复杂度降至 $O(nd)$ ，并将推理显存占用从标准注意力的 $O(nd)$ （随序列长度线性增长）降至与序列长度无关的 $O(d)$ （仅需维护两个 d 维累积向量）。从理论上证明了该机制在长文本场景下的信息保持能力和计算效率优势。
4. **实证验证**：在 WikiText-103 语言建模基准和五个标准回归数据集上进行了系统的实验验证，证明了 DAM 在保持与标准注意力机制可比的语言建模能力的同时实现了线性复杂度，以及 DATP 在维持预测性能稳定的前提下通过演化动力学将思维点数量压缩约 75%。

1.4 论文组织结构

本文的剩余部分组织如下：第 2 章系统回顾相关研究工作，涵盖 KV 缓存优化、注意力机制替代方案、生成对抗网络与混合专家模型等关键背景；第 3 章详细介绍本文提出的方法，包括分聚思维点网络（DATP）和分歧聚合机制（DAM）的完整数学框架、PyTorch 参考实现和架构设计；第 4 章报告实验设置与结果分析；第 5 章对实验结果和方法的局限性进行深入讨论；第 6 章总结全文并提出未来研究方向。

2 相关工作

2.1 KV 缓存优化：MQA、GQA 与 MLA

在自回归语言模型的推理过程中，KV 缓存（Key-Value Cache）是显存占用的主要来源。对于具有 L 层、 h 个注意力头、隐空间维度为 d 的 Transformer 模型，在处理长度为 n 的序列时，KV 缓存的总大小为：

$$\text{KV-Cache} = 2 \times L \times h \times d_h \times n \times \text{precision} \quad (1)$$

其中 $d_h = d/h$ 为每个头的维度。以 LLaMA2-7B 为例 ($L = 32, h = 32, d_h = 128$), 在 FP16 精度下每生成一个 Token 需占用约 0.5MB 的 KV 缓存, 当批量处理长序列时, KV 缓存很快就会耗尽 GPU 的高带宽内存 (HBM)。

多查询注意力 (Multi-Query Attention, MQA) [2] 由 Shazeer 在 2019 年提出, 是最早针对 KV 缓存问题的系统性解决方案之一。MQA 的核心思想是让所有注意力头共享同一组 Key 和 Value 投影矩阵, 同时保持独立的 Query 投影。这一设计将 KV 缓存的大小从 $O(h \times n)$ 直接降至 $O(1 \times n)$, 即压缩比为 $1/h$ 。MQA 在 PaLM、StarCoder 和 Gemini 等模型中得到了广泛应用。然而, MQA 的代价是注意力的表达能力有所下降——所有头被迫使用相同的键值表示, 在需要多样化注意力模式的复杂任务上可能出现性能退化。

分组查询注意力 (Grouped-Query Attention, GQA) [3] 由 Ainslie 等人于 2023 年提出, 在 MHA 和 MQA 之间找到了一个折中方案。GQA 将 h 个查询头划分为 g 个组 ($1 < g < h$), 每个组内共享同一组 Key-Value 投影。当 $g = h$ 时退化为 MHA, 当 $g = 1$ 时退化为 MQA。LLaMA2-70B 采用 $g = 8$ 的 GQA 配置, 实现了约 8 倍的 KV 缓存压缩, 同时在长文本任务上保持了与 MHA 近乎一致的性能。LLaMA3、ChatGLM2/3 和 DeepSeek-V1 等模型也广泛采用了 GQA。

多头潜在注意力 (Multi-Head Latent Attention, MLA) [4] 由 DeepSeek 团队在 2024 年的 DeepSeek-V2 中提出, 代表了 KV 缓存优化的最新范式转换。MLA 不再通过头共享来降低 KV 缓存, 而是将 Key 和 Value 联合压缩到一个低维潜在空间中。具体而言, MLA 通过一个下投影矩阵 W^{DKV} 将输入隐藏状态映射到维度为 d_c 的潜在向量 $\mathbf{c}$, 推理时仅缓存此潜在向量, Key 和 Value 在需要时通过上投影实时重建。通过矩阵吸收技巧 (将上投影吸收到 Query 投影中), MLA 在推理时消除了显式解压的计算开销。DeepSeek-V2 使用 $d_c = 512$ 的潜在维度, 实现了约 30 倍的 KV 缓存压缩, 从而支撑了 128K Token 的超长上下文窗口。

表 1 KV 缓存优化方案对比

方法	KV 缓存副本数	压缩比
MHA (Vaswani et al., 2017) [1]	h	$1\times$
MQA (Shazeer, 2019) [2]	1	$1/h$
GQA (Ainslie et al., 2023) [3]	g	g/h
MLA (DeepSeek, 2024) [4]	$d_c + d_{\text{rope}}$	$\sim 10\text{--}30\times$

2.2 注意力机制的替代方案：从线性注意力到状态空间模型

在降低注意力计算复杂度方面，学术界已进行了大量探索。这些工作大致可以分为线性注意力方法、状态空间模型（SSMs）和混合架构三个类别。

线性注意力方法的核心思路是利用核函数的性质，将注意力计算从 $(QK^T)V$ 的“先点积后加权”顺序重新排列为 $Q(K^TV)$ 的“先加权后点积”顺序，从而将复杂度从 $O(n^2)$ 降至 $O(nd^2)$ 或 $O(nd)$ 。线性 Transformer (Linear Transformer) 由 Katharopoulos 等人于 2020 年首次提出 [5]，使用 ELU 激活函数加 1 作为核函数来保证 Key 投影的非负性。Performer (Choromanski et al., 2021) [6] 采用正交随机特征来近似 softmax 核，在多个基准上取得了与标准 Transformer 竞争的性能。Gated Linear Attention (GLA, Yang et al., ICML 2024) [24] 引入了数据依赖的门控机制和硬件高效的 FlashLinearAttention 实现，在语言建模任务上展现了与 LLaMA 架构竞争的能力。Hedgehog (Zhang et al., 2024) [26] 通过可训练的 softmax 模拟机制，实现了线性注意力对标准注意力的高质量逼近。BASED (Arora et al., 2024) [25] 则将线性注意力与滑动窗口注意力混合，在 24 倍的吞吐量提升下保持了与 FlashAttention-2 相媲美的召回性能。

状态空间模型 (State Space Models, SSMs) 是另一条重要的技术路线。SSM 的理论基础可以追溯到控制论中的线性时不变系统，其核心思想是用一个潜在的状态向量来动态编码序列的历史信息。Gu 等人提出的 S4 模型 [7] 首次将结构化状态空间应用于长序列建模。Mamba (Gu & Dao, 2023) [8] 通过引入输入依赖的选择性机制 (Selective SSM)，打破了 S4 的线性时不变限制，使状态转移矩阵 A 、输入投影矩阵 B 和输出投影矩阵 C 都成为输入的函数，大幅提升了 SSM 的上下文建模能力。Mamba-2 (Dao & Gu, 2024) [9] 进一步揭示了 SSM 与线性注意力之间的深层数学联系——结构化状态空间对偶性 (SSD)，并通过优化的并行扫描算法实现了 2–8 倍的训练加速。Jamba (Lieber et al., 2024) [31] 提出了一种混合 Transformer-Mamba 架构，结合了全注意力层的表达能力和 Mamba 层的长序列效率。Retentive Network (RetNet, Sun et al., 2023) [30] 则通过引入指数衰减的保留机制，在训练并行性和推理效率之间取得了有竞争力的平衡。RWKV 系列模型 (Peng et al., 2023) [10] 采用了一种 RNN 风格的线性递归机制，在语言建模任务上展现了与 Transformer 竞争的性能。

TTT (Test-Time Training) [11] 由 Sun 等人于 2024 年提出，开创了一种全新的序列建模范式。TTT 层将隐藏状态本身视为一个机器学习模型（线性模型或 MLP），而状态更新规则则是该模型在自监督重构损失上的一步梯度下降。由于隐藏状态在推理阶段也在持续学习（即测试时训练），TTT 层展现了超越固定参数 RNN 的表达能力，同时保持了线性复杂度。TTT-Linear 在 125M–1.3B 参数量级上展现了优于 Mamba 的困惑度表现，特别是在超过 32K 的长序列上。

表 2 注意力替代方案复杂度对比

方法	训练复杂度	推理复杂度	推理显存
标准注意力 (Transformer) [1]	$O(n^2d)$	$O(n^2d)$	$O(n)$
线性注意力 (Linear Transformer) [5]	$O(nd^2)$	$O(nd^2)$	$O(d^2)$
Mamba (S6) [8]	$O(nd)$	$O(nd)$	$O(d)$
Mamba-2 (SSD) [9]	$O(nd)$	$O(nd)$	$O(d)$
RWKV [10]	$O(nd)$	$O(nd)$	$O(d)$
TTT-Linear [11]	$O(nd)$	$O(nd)$	$O(d)$
DAM (本文)	$O(nd)$	$O(nd)$	$O(d)$

DAM 与其他替代方案的对比分析。在表2所列的注意力替代方案中，线性注意力 (Linear Transformer) 在推理时需要维护 $O(d^2)$ 大小的 KV 状态矩阵，属于中等显存开销；Mamba、Mamba-2、RWKV 等状态空间模型及 RNN 风格模型将推理状态压缩至 $O(d)$ 的固定维度向量，与 DAM 处于同一量级。然而，DAM 相比这些方案具有一项独特优势：**DAM 完全摒弃了矩阵乘法**。标准注意力依赖 QK^T 矩阵乘法 (计算复杂度 $O(n^2d)$)，线性注意力虽重排计算顺序但仍需 $Q(K^TV)$ 形式的矩阵乘法 ($O(nd^2)$)，Mamba 和 RWKV 在状态更新中同样涉及输入依赖的线性投影矩阵运算。相比之下，DAM 的核心计算仅由逐元素乘法 ($\phi(K) \cdot V$)、累加 (cumsum)、逐元素除法 ($\frac{kv_cumsum}{den_cumsum}$) 和哈达玛积 ($\phi(Q) \odot \mathcal{M}_t$) 构成，无需任何 Q 与 K 之间的矩阵乘法，计算路径更为精简。在推理显存方面，DAM 仅需维护两个形状为 $[1, d]$ 的累积向量 (kv_cumsum 和 den_cumsum)，与序列长度 n 完全解耦，存储开销恒定为 $O(d)$ 。RWKV 和 Mamba-2 虽也将推理状态压缩至 $O(d)$ 量级，但其状态更新涉及多次矩阵-向量乘法，在批推理和大规模部署场景下矩阵乘法引擎的功耗和延迟开销不容忽视。DAM 以纯逐元素运算实现相同量级的推理显存，在资源受限的边缘设备和长序列推理场景中具有更为明显的效率优势。

2.3 GAN、MoE 与强化学习的核心思想借鉴

本文提出的 DATP 方法论体系，在思想上融合了生成对抗网络 (GAN)、混合专家模型 (MoE) 和强化学习 (Reinforcement Learning, RL) 三个领域的核心洞见，借用了 GAN 的纠错直觉、MoE 的稀疏激活优势以及 RL 的交互思想，在数学上通过“残差就地嵌入”与“生态聚合遗忘”机制实现流式推理期的稳健正向进化。

生成对抗网络 (Generative Adversarial Network, GAN) [12] 由 Goodfellow 等人于 2014 年提出，通过生成器与鉴别器的零和博弈实现对抗训练。其核心洞见在于：鉴别器充当外部质量评判者，通过反馈信号驱动生成器能力提升。这一“纠错直

觉”被直接借鉴到 DATP 的设计中——审判官网络 $g_\phi(\cdot)$ 预测当前基座模型发生显著错误的概率，为思维点的嵌入与激活提供决策依据。与 GAN 不同的是，DATP 中的审判官并非与基座模型进行零和对抗，而是作为一种**解耦的认知元监控器**发挥辅助性的认知边界感知功能。

混合专家模型 (Mixture of Experts, MoE) [27, 13, 14] 的核心思想是通过门控网络对每个输入动态激活少量专家 (Top- k 稀疏激活)。MoE 对本文的启发体现在两个层面：其一，**稀疏激活优势**——思维点池每次推理仅激活与当前输入最相关的一个（或零个）思维点；其二，**模块化知识存储**——每个思维点是独立的局部专家，承载特定知识区域的纠错能力。MoE 与 DATP 的根本差异在于：MoE 的专家数量和参数在训练阶段固定，通过大规模梯度优化训练；而 DATP 的思维点是**非参数化的**，在推理阶段**按需动态创建和遗忘**，通过少数几步在线梯度下降完成学习。

强化学习 (Reinforcement Learning, RL) [15] 的核心思想是通过智能体与环境的交互，根据奖励信号学习最优策略。RL 对本文的启示在于：智能体应当通过与外部世界的交互来判断自身行为的正确性并做出调整。DATP 将这一思想具体化为“模型-审判官-环境”的三元交互回路，其中“奖励信号”是真实标签 y 与基座预测 $\hat{y}_{\text{base}}$ 之间的残差向量，使思维点能够学习到丰富的方向性修正信息。

2.4 持续学习与灾难性遗忘

持续学习 (Continual Learning)，又称终身学习 (Lifelong Learning) 或增量学习 (Incremental Learning)，旨在赋予神经网络在不遗忘旧知识的前提下持续吸收新知识的能力。这一领域的核心挑战是**灾难性遗忘 (Catastrophic Forgetting)** [20]——当网络在新数据上进行参数更新时，旧任务对应的权重配置会被覆盖。Wang 等人 2024 年在 IEEE TPAMI 上发表的《A Comprehensive Survey of Continual Learning》[19] 将现有方法归纳为三大类：

- **正则化方法 (Regularization-based)**：如弹性权重巩固 (EWC, Kirkpatrick et al., 2017) [20] 和突触智能 (SI, Zenke et al., 2017) [22]，通过对重要参数施加额外的正则化惩罚来减缓遗忘。
- **回放方法 (Rehearsal-based)**：如经验回放 (Experience Replay) 和生成回放 (Generative Replay)，通过存储或生成旧任务的代表性样本来在训练新任务时保持旧知识。
- **参数隔离方法 (Parameter Isolation-based)**：如渐进式神经网络 (Progressive Networks, Rusu et al., 2016) [21] 和 PackNet (Mallya et al., 2018) [28]，通过为新任务分配独立参数子空间来完全避免参数覆盖。

Zheng 等人 2024 年的《Towards Lifelong Learning of Large Language Models: A Survey》[23] 进一步将 LLM 的持续学习策略划分为内部知识更新（在参数空间内）和

外部知识增强（在参数空间外）两大类，指出外部方法（如检索增强生成 RAG）虽避免了遗忘，但依赖于外部知识库的质量和检索精度。

本文的 DATP 方法属于**参数隔离方法的非参数化扩展**：我们不修改基座参数，而是在参数空间之外构建了一个新的、独立演化的思维点池。与传统参数隔离方法不同的是，DATP 的思维点不是预先为不同任务分配的，而是在流式交互中**自动生长、聚合和修剪**的，因此天然适应于非平稳环境中的开放域持续学习场景。

3 本文提出的方法

本章是全论文的核心，系统阐述分聚思维点网络 (DATP) 和分歧聚合机制 (DAM) 的完整方法论体系。第3.1节首先从定义层面对思维点和分歧度进行严格的数学刻画；第3.2节详细介绍 DATP 的架构设计、算法流程和演化动力学；第3.3节深入 DAM 机制的数学原理、计算特性和复杂度分析。

3.1 思维点与分歧度的数学定义

3.1.1 思维点的形式化定义

定义 3.1 (思维点, Thought Point). 令 $\mathcal{X} \subseteq \mathbb{R}^d$ 为输入特征空间, $\mathcal{Y} \subseteq \mathbb{R}^k$ 为输出空间。一个思维点是特征空间中的一个局部化知识单元，形式化定义为三元组：

$$tp_k = \langle \mathbf{a}_k, \mathbf{W}_k, H_k \rangle \quad (2)$$

其中：

- $\mathbf{a}_k \in \mathbb{R}^d$ 为**空间锚点特征** (Anchor Feature)，记录了该思维点被创建时对应输入样本的隐空间特征表示，作为后续评估新输入与思维点之间分歧度的参照基准。
- $\mathbf{W}_k$ 为**局部残差修正权重** (Local Residual Correction Weight)，存储了从输入特征到输出残差的映射能力。其参数规模和结构可以根据任务需求灵活设计（如单层线性变换或小型 MLP）。
- $H_k \in [0, 1]$ 为**生物健康度** (Biological Health Score)，是一个模拟生物突触可塑性 与修剪的标量状态值，驱动着思维点的生命周期管理。

定义 3.2 (思维点池, Thought-Point Pool). 思维点池 $\mathcal{M}$ 是当前所有活跃思维点的集合：

$$\mathcal{M} = \{tp_1, tp_2, \dots, tp_K\}, \quad K = |\mathcal{M}| \leq K_{\max} \quad (3)$$

其中 $K_{\max}$ 为系统预先设定的最大容量上限，用以防止内存无限增长。

为什么叫“思维点”？ 这一命名的灵感直接源于对人类认知机制的观察。海马体记忆索引理论 (Teyler & DiScenna, 1986) [32] 指出，海马体并不直接存储详细的感

知记忆，而是存储指向皮层区域的索引指针，类似于分布式的内容寻址存储器。稀疏编码理论 (Olshausen & Field, 1996) [33] 揭示，初级视觉皮层的神经元对自然场景的响应具有稀疏性和局部化特性。Quiroga 等人 (2005) [34] 发现的“概念神经元”（如著名的“Jennifer Aniston 神经元”）为离散化、压缩化的知识表征提供了直接的神经生理学证据。预测编码理论 (Rao & Ballard, 1999; Friston, 2005) [35, 36] 则将大脑描述为层级化的预测机器，在预测与实际输入出现分歧时更新内部模型。综合上述发现，人脑的知识表征系统具备三个核心特性：(1) **压缩性**——信息被抽象为紧凑的神经表征；(2) **离散性**——知识被组织为可独立激活的单元；(3) **分歧驱动**——仅在预测与输入显著分歧时才进行知识更新。我们使用“点” (Point) 这一几何隐喻，因为在高维隐空间中，每个思维锚点代表着特征流形上的一个具象位置，思维点之间的分歧度 (欧氏距离) 则表征了知识区域的几何边界。

3.1.2 分歧度的形式化定义

定义 3.3 (分歧度, Divergence). 给定输入样本经过基座特征提取器后的隐空间特征 $h_x \in \mathbb{R}^d$ 和思维点 tp_k 的锚点特征 $\mathbf{a}_k$ ，两者之间的**空间分歧度** (Spatial Divergence) 定义为：

$$D(h_x, tp_k) = \|h_x - \mathbf{a}_k\|_2 = \sqrt{\sum_{i=1}^d (h_{x,i} - a_{k,i})^2} \quad (4)$$

更一般地，对于 DAM 机制中的序列处理场景，**隐式分歧度** (Implicit Divergence) 定义为激活 Query 与凝聚思维点之间的逐元素调制：

$$\Phi(Q_t) = \text{ELU}(Q_t) + 1.0 \quad (5)$$

为什么叫“分歧度”？ 在传统的 Transformer 自注意力机制中，Query 和 Key 之间的点积相似度 (Dot-Product Similarity) 是核心计算原语，它衡量的是“新输入与历史输入有多相似”。然而，相似度度量存在两个根本性的问题：(1) **方向性缺失**——点积相似度只能表示“有多相关”，无法区分“正相关”、“负相关”和“冲突”三种本质不同的关系；(2) **尺度敏感性**——相似度的量级受特征范数影响严重，在不同层、不同头之间难以进行统一的阈值设定。分歧度则更为精确地刻画了当前输入与既有认知之间的**不一致程度**或**认知冲突强度**。在认知层面，“分歧”天然带有“需要被解决”的行动意图——高分歧触发认知修正，低分歧维持现状。这一概念从“相似”到“分歧”的转换，是将注意力的“信息检索”范式升级为“认知纠错”范式的关键跃迁。

3.1.3 思维点与分歧度的认知闭环

思维点和分歧度共同构成了一个完整的认知闭环系统。图1描绘了这一循环的逻辑流程：




图 1 思维点与分歧度的认知闭环

这一闭环的特殊之处在于：传统神经网络的“学习 → 预测”是单向过程，而 DATP 实现了“预测 → 评价 → 学习 → 再预测”的循环过程，每个循环都使模型的知识边界发生微小的扩展或修正，从而在流式交互中实现知识的正向积累。

3.2 分聚思维点网络（DATP）

分聚思维点网络（Divergent-Aggregate Thought-Point Network, DATP）是一种赋予冻结基座模型在推理部署阶段进行流式持续自我学习的新型网络架构。本节从整体架构、基座网络设计、审判官机制、思维点池操作和演化动力学五个层次系统阐述 DATP 的方法论。

3.2.1 整体架构

DATP 由三个功能解耦的核心组件构成：

1. **通用基座网络 f_θ （系统 1）**：负责提取输入特征并给出基准预测。在部署阶段，其参数 θ 被完全冻结。
2. **解耦审判官网络 g_ϕ （环境代理）**：负责对基座网络的输出进行质量评估，预测当前输入导致基座模型发生显著错误的概率。
3. **动态思维点池 $\mathcal{M}$ （系统 2）**：由一组动态创建、在线学习和自适应演化的思维点构成，在基座网络出错时提供局部残差修正。

传统深度学习模型在部署上面临两难困境（Dilemma）：全面微调（Full Fine-tuning）计算代价高昂且容易引发灾难性遗忘；而静态拒绝微调（Rejection）则缺乏对未知环境的自适应能力。DATP 通过上述三元架构突破了这一困境。

三者之间的数学关系可以表述为：

$$\hat{y}_{\text{final}} = \begin{cases} f_{\theta}(x), & g_{\phi}(x) \leq \tau_{\text{error}} \quad (\text{快速通道}), \\ f_{\theta}(x) + \text{Expert}_{k^*}(h_x), & g_{\phi}(x) > \tau_{\text{error}}, \\ f_{\theta}(x) + \text{NewExpert}(h_x, y_{\text{true}} - f_{\theta}(x)), & D_{\min} \leq \tau_{\text{dist}} \quad (\text{慢速通道-命中}), \\ f_{\theta}(x) + \text{NewExpert}(h_x, y_{\text{true}} - f_{\theta}(x)), & g_{\phi}(x) > \tau_{\text{error}}, \\ & D_{\min} > \tau_{\text{dist}} \quad (\text{慢速通道-未命中}). \end{cases} \quad (6)$$

其中 $h_x = \text{Extractor}_{\theta}(x)$ 为输入经过基座特征提取器后的隐层特征, $D_{\min} = \min_k \|h_x - \mathbf{a}_k\|_2$ 为最小分歧度。

DATP 架构的整体流程图如图2所示:




图 2 DATP 架构整体流程图

3.2.2 系统 1: 通用基座网络（直觉式快思考）

通用基座网络 f_{θ} 是 DATP 的直觉式推理主体。其设计遵循简洁有效的原则, 由一个多层感知机 (MLP) 特征提取器和一个线性回归器组成:

$$h_x = \text{Extractor}_{\theta}(x) = \text{ReLU}(\mathbf{W}_2 \cdot \text{ReLU}(\mathbf{W}_1 x + \mathbf{b}_1) + \mathbf{b}_2) \quad (7)$$

$$\hat{y}_{\text{base}} = \text{Regressor}(h_x) = \mathbf{W}_{\text{reg}} h_x + b_{\text{reg}} \quad (8)$$

基座网络在离线训练阶段通过标准的监督学习进行预训练, 完成后其参数 θ 被完全冻结 (requires_grad = False)。参数冻结具有三重重要意义:

- **消除灾难性遗忘:** 基座网络的核心泛化能力不会被任何后续的在线更新所破坏。
- **降低在线计算开销:** 基座网络的前向传播不需要任何梯度计算, 推理速度保持最快。
- **提供稳定的对比参照:** 基座网络的固定预测为思维点的残差学习提供了稳定的基准线。

3.2.3 解耦审判官机制（认知边界感知）

让模型知道“自己是否在犯错”是实现自动自我学习的前提。传统模型的输出仅包含预测值，不包含关于预测可靠性的元认知信息。DATP 通过引入一个结构轻量但功能关键的审判官网络 g_ϕ 来填补这一空白：

$$P(\text{Wrong} | x) = g_\phi(x) = \sigma(\mathbf{W}_J \cdot \text{ReLU}(\mathbf{W}_{J1}x + \mathbf{b}_{J1}) + b_J) \in [0, 1] \quad (9)$$

其中 σ 为 Sigmoid 激活函数，确保输出被归一化到 $[0, 1]$ 区间。

审判官网络的训练目标不是直接预测最终输出，而是预测基座网络的预测错误概率——这对审判官来说是一个更为简单且定义良好的二元分类问题。训练时，我们使用基座网络的预测误差作为监督信号：

$$\text{label}_{\text{judge}} = \mathbb{I}[|\hat{y}_{\text{base}} - y_{\text{true}}| > \eta] \quad (10)$$

其中 η 为错误判定阈值（例如 $\eta = 0.35$ 在标准化标签空间下）。审判官的训练损失为二元交叉熵：

$$\mathcal{L}_{\text{judge}} = -\mathbb{E}_x[\text{label} \cdot \log g_\phi(x) + (1 - \text{label}) \cdot \log(1 - g_\phi(x))] \quad (11)$$

决策门控规则设定了快速通道与慢速通道的分界：

$$\text{Route} = \begin{cases} \text{Fast Route (System 1)}, & g_\phi(x) \leq \tau_{\text{error}} \\ \text{Slow Route (System 2)}, & g_\phi(x) > \tau_{\text{error}} \end{cases} \quad (12)$$

其中 $\tau_{\text{error}} = 0.55$ 为经验设定的门控阈值，略高于 0.5 以平衡灵敏度和特异性。这一设计使得模型能够按需计算（Compute-on-Demand），在保证准确率的同时大幅降低了平均推理延迟。

认知科学关联：元认知监控（Metacognitive Monitoring）。审判官网络的认知科学基础是人类元认知中的两个核心判断过程——“知道的判断”（Judgment of Knowing, JOK）和“学习的判断”（Judgment of Learning, JOL）。JOK 指个体在尝试提取记忆之前对自身是否知道某事的预判（例如：“我答得出这道题吗？”），而 JOL 指个体在学习后对自身掌握程度的评估（例如：“我现在学会了吗？”）。Nelson 和 Narens (1990) 的元认知框架 [37] 将这两个过程描述为从“对象层”（Object Level）流向“元层”（Meta Level）的监控信号。在 DATP 中，审判官网络 g_ϕ 承担了元认知监控的角色：它接收对象层（基座网络的隐状态）的信息，输出元层判断（ $P(\text{Wrong}|x)$ ），从而决定是否需要激活系统 2（思维点池）进行慢思考。这种元认知驱动的认知资源分配策略，使得 DATP 在计算效率和预测精度之间实现了动态平衡——在模型有把握时走快速通道，在模型不确定时才调动额外的计算资源进行深度修正。

3.2.4 动态思维点池操作

思维点池的核心操作包括三个：匹配（Routing）、修正（Correction）和嵌入（Embedding）。

匹配操作——基于分歧度的最近邻路由：

当样本被路由至慢速通道时，首先计算其隐空间特征 h_x 与所有思维点锚点的分歧度：

$$k^* = \arg \min_{k \in \{1, \dots, K\}} \|h_x - \mathbf{a}_k\|_2 \quad (13)$$

$$D_{\min} = \min_{k \in \{1, \dots, K\}} \|h_x - \mathbf{a}_k\|_2 \quad (14)$$

若 $D_{\min} \leq \tau_{\text{dist}}$ （距离阈值为 1.5），则判定为**命中（Hit）**，激活对应思维点；否则为**未命中（Miss）**，触发生成新思维点。

修正操作——残差补丁（Residual Patch）：

命中的思维点通过其局部专家权重生成残差修正量：

$$\Delta_k(h_x) = \text{Expert}_k(h_x) = \mathbf{W}_k h_x + b_k \quad (15)$$

最终的输出为基座预测与残差修正的加权组合：

$$\hat{y}_{\text{final}} = \hat{y}_{\text{base}} + \lambda \cdot \text{clamp}(\Delta_k(h_x), -0.5, 0.5) \quad (16)$$

其中 $\lambda = 0.2$ 为修正强度系数，clamp 操作将修正量裁剪至 $[-0.5, 0.5]$ 区间以防止单次修正引发过度调整。

嵌入操作——即时在线学习（On-the-Fly Learning）：

当分歧度超过阈值且思维点池未饱和时（ $K < K_{\max}$ ），系统在当前样本的特征位置即时创建一个全新的思维点：

$$\mathcal{M} \leftarrow \mathcal{M} \cup \{tp_{\text{new}}\}, \quad \mathbf{a}_{\text{new}} = h_x \quad (17)$$

新思维点的局部专家权重通过少数几步在线梯度下降对当前残差目标进行即时学习：

$$\mathbf{W}_{\text{new}}^{(t+1)} \leftarrow \mathbf{W}_{\text{new}}^{(t)} - \alpha \nabla_{\mathbf{W}} \mathcal{L}(\text{Expert}_{\text{new}}(h_x), y_{\text{true}} - \hat{y}_{\text{base}}) \quad (18)$$

默认学习步数为 5 步¹，学习率 $\alpha = 0.01$ ，并加入 L2 正则化项 $0.01 \cdot \|\mathbf{W}\|_2^2$ 以防止对单一样本的过拟合。这一设计的认知学隐喻是：当遇到一个“完全不懂”的新问

¹该参数需要根据模型参数量和数据集规模进行调整：参数量越大、数据分布越复杂，所需的学习步数通常越多；反之对于简单任务和较小模型，减少步数可提升效率。

题时，人类会花费额外的精力进行专注的学习和记忆，而非仅仅浅尝辄止。

3.2.5 演化动力学：聚合与遗忘机制

在持续流式学习的场景下，思维点池面临两大风险：（1）**内存爆炸（Memory Explosion）**——思维点数量随交互流无限增长，最终耗尽系统资源；（2）**噪声过拟合**——由于偶发的噪声样本或对抗性输入而创建的思维点，长期占据存储空间却无实际价值。为解决这些问题，DATP 创新性地引入了模拟生物神经系统突触修剪的演化动力学机制，包含空间聚合和生物遗忘两个互补的进程。




图 3 思维点池演化动力学流程图

空间聚合机制（Spatial Aggregation Mechanism）：

当两个思维点在高维空间中的距离小于聚合阈值时（距离 $< 0.4 \cdot \tau_{\text{dist}}$ ），它们被视为覆盖了同一知识区域的不同实例，执行平权融合：

$$\mathbf{a}_{\text{merged}} = \frac{\mathbf{a}_i + \mathbf{a}_j}{2} \quad (19)$$

$$\mathbf{W}_{\text{merged}} = \frac{\mathbf{W}_i + \mathbf{W}_j}{2} \quad (20)$$

$$H_{\text{merged}} = \min(1.0, \max(H_i, H_j) + 0.1) \quad (21)$$

聚合机制的学术意义在于：它将散落的“孤立错题点”逐步凝聚为具有更高泛化能力的“局部知识区域”。这一过程与人脑将零散经验逐步归纳为通用规律的认知发展过程高度一致——重复出现的相似错误不再需要多个独立的思维点来修补，一个凝聚后的高健壮性节点便能有效覆盖。

Algorithm 1 DATP 核心算法伪代码: DATP Forward Pass with Evolutionary Dynamics

Require: x (input batch), y_{env} (optional environment labels)

Ensure: final_predictions

```

1:  $\tau_{\text{error}} = 0.55, \tau_{\text{dist}} = 1.5, K_{\text{max}} = 150, \lambda = 0.2, \text{learning\_steps} = 5, \alpha = 0.01$ 
2:  $h_x \leftarrow \text{BaseModel.FeatureExtractor}(x)$ 
3:  $\hat{y}_{\text{base}} \leftarrow \text{BaseModel.Regressor}(h_x)$ 
4:  $p_{\text{wrong}} \leftarrow \text{JudgeModel}(x)$  ▷ 认知不确定性估计
5: for each sample  $i$  in batch do
6:   if  $p_{\text{wrong}}[i] \leq \tau_{\text{error}}$  then ▷ 快速通道 (系统 1)
7:      $\hat{y}_{\text{final}}[i] \leftarrow \hat{y}_{\text{base}}[i]$ 
8:   else ▷ 慢速通道 (系统 2)
9:      $D_{\text{min}}, k^* \leftarrow \min_k \|h_x[i] - \mathbf{a}_k\|_2$  ▷ 分歧度路由
10:    if  $D_{\text{min}} \leq \tau_{\text{dist}}$  then ▷ 命中已有思维点
11:       $\Delta \leftarrow \text{clamp}(\text{Expert}_{k^*}(h_x[i]), -0.5, 0.5)$ 
12:       $\hat{y}_{\text{final}}[i] \leftarrow \hat{y}_{\text{base}}[i] + \lambda \cdot \Delta$ 
13:       $tp_{k^*}.\text{usage\_count} += 1$ 
14:      if  $y_{\text{env}}$  is available then
15:         $\text{residual} \leftarrow y_{\text{env}}[i] - \hat{y}_{\text{base}}[i]$ 
16:         $tp_{k^*}.\text{train\_on\_the\_fly}(h_x[i], \text{residual}, 2 \text{ steps})$ 
17:      end if
18:    else ▷ 未命中 – 嵌入新思维点
19:      if  $|\mathcal{M}| < K_{\text{max}}$  and  $y_{\text{env}}$  is available then
20:         $tp_{\text{new}} \leftarrow \text{create\_thought\_point}(h_x[i])$ 
21:         $\text{residual} \leftarrow y_{\text{env}}[i] - \hat{y}_{\text{base}}[i]$ 
22:         $tp_{\text{new}}.\text{train\_on\_the\_fly}(h_x[i], \text{residual}, 5 \text{ steps})$ 
23:         $\hat{y}_{\text{final}}[i] \leftarrow \hat{y}_{\text{base}}[i] + \lambda \cdot \text{clamp}(tp_{\text{new}}(h_x[i]), -0.5, 0.5)$ 
24:         $\mathcal{M}.\text{add}(tp_{\text{new}})$ 
25:      else
26:         $\hat{y}_{\text{final}}[i] \leftarrow \hat{y}_{\text{base}}[i]$  ▷ 回退至基座预测
27:      end if
28:    end if
29:  end if
30: end for
31:  $\text{ApplyEvolutionaryDynamics}(\mathcal{M})$  ▷ 聚合 + 遗忘
32: return  $\hat{y}_{\text{final}}$ 

```

生物遗忘机制 (Biological Forgetting Mechanism):

思维点的健康度 H_k 在每个演化周期结束时根据其近期使用情况被动态更新:

$$H_k^{(t+1)} = \begin{cases} \min(1.0, H_k^{(t)} + 0.05), & \text{if UsageCount}_k \geq 1 \quad (\text{被激活, 恢复活力}) \\ H_k^{(t)} - 0.15, & \text{if UsageCount}_k = 0 \quad (\text{孤立闲置, 自然衰减}) \end{cases} \quad (22)$$

当 $H_k < 0.2$ 时, 该思维点被判定为“死亡”, 从池中永久移除。

遗忘机制的必要性在理论上具有三重意义:

1. **有界性保证 (Boundedness)**: 确保思维点池的大小在无限流式输入中保持有限, 满足持续学习系统的资源约束。
2. **噪声鲁棒性 (Noise Robustness)**: 因噪声或偶发错误而创建的低频思维点会自然地进入衰减 $\rightarrow$ 遗忘的生命周期, 无需专门的异常检测模块。
3. **概念漂移适应 (Concept Drift Adaptation)**: 当数据分布发生迁移时, 基于旧分布创建但不再被使用的思维点会逐渐衰退并被新思维点取代, 实现了“遗忘旧知识以接纳新知识”的动态平衡。

3.3 分歧聚合机制 (DAM)

分歧聚合机制 (Divergence Aggregation Mechanism, DAM) 是 DATP 体系中的高效底层计算算子。它在保持与标准注意力机制可比的语言建模能力的同时, 将时间复杂度和空间复杂度从 $O(n^2)$ 和 $O(n)$ 分别降至 $O(nd)$ 和 $O(d)$ (与序列长度 n 完全无关, 仅需维护两个 d 维累积向量)。本节从线性记忆锚定、隐式分歧度门控、层归一化策略和复杂度分析四个维度展开论述。

3.3.1 线性记忆锚定与思维点凝聚

标准缩放点积注意力 (Scaled Dot-Product Attention, SDPA) 的计算公式为:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (23)$$

这一公式隐含地将每个历史 Token 视为独立的记忆单元, 当前 Token 通过 softmax 归一化后的相似度权重对所有历史 Token 的值进行加权平均。这种做法导致每一层的计算复杂度为 $O(n^2d)$, 且在长文本场景下出现了信息稀释 (Information Dilution)——大量语义上无关的历史 Token 虽然在 softmax 中获得了微小的权重, 但它们的累积效应稀释了真正重要的历史信息。

DAM 的核心思想是对这一范式进行根本性的重构: **不再保留每一个历史微观状态, 而是将动态的时序特征实时压缩、凝聚为一个统一的宏观“时序思维点”(Temporal Thought Point)**。该思维点随时间的推进而动态演进, 每一个新 Token 的到来并不

会增加计算或存储的负担，而只是更新这个凝聚态的认知表征。

具体而言，DAM 首先通过非负激活函数 $\phi(\cdot)$ 对 Key 矩阵进行投影，将 Key 的值映射到严格为正的空间中。这一非负性要求是关键——它使得 $\phi(K)$ 可以天然地充当历史信息流的**认知权重测度** (Cognitive Weight Measure)，类似于概率论中的测度，为后续的归一化操作提供了数学上的合法性。本文选择 $\phi(\cdot) = \text{ELU}(\cdot) + 1.0$ ，并辅以 LayerNorm 进行输出归一化以保障训练稳定性。这一选择与线性 Transformer (Katharopoulos et al., 2020) 的核函数一致，在此基础上本文引入层归一化 (LayerNorm) 作为输出后处理，确保训练稳定性并使其服务于 DATP 分歧度统一框架。

对于输入序列在时间步 t 的历史沉淀，DAM 将当前步之前的所有历史信息凝聚为统一的动态思维点 $\mathcal{M}_t$ ：

$$\mathcal{M}_t = \frac{\sum_{\tau=1}^t \phi(K_\tau) \cdot V_\tau}{\sum_{\tau=1}^t \phi(K_\tau)} = \frac{\text{kv_cumsum}_t}{\text{den_cumsum}_t} \quad (24)$$

这一公式具有深刻的物理意义：

- **分母 den_cumsum_t** ：模型至今为止积攒的“总思维能量”或“认知质量”。它持续单调增长，代表着模型见过的所有有效信息的累积总量。
- **分子 kv_cumsum_t** ：带有语义特征的“总记忆显影”。每一个 $\phi(K_\tau) \cdot V_\tau$ 是一个被其认知权重缩放后的语义贡献。
- **商 $\mathcal{M}_t$** ：一个在高维隐空间中唯一定义的、动态演进的“核心思维状态点”。它是历史上下文的归一化凝聚表征。

这种基于累积累加 (Cumulative Sum) 的线性递归形式赋予了 DAM 三个关键性质：

1. **恒定存储**：无论序列长度为多少，模型仅需维护 kv_cumsum 和 den_cumsum 两个大小固定为 $O(d)$ 的状态张量。
2. **增量更新**：每个新 Token 仅需一次加法和除法操作即可更新全局思维点，计算量为 $O(d)$ 。
3. **因果兼容**：通过 `torch.cumsum` 操作可以高效实现因果掩码，确保每个位置的思维点仅包含当前位置之前的历史信息。

3.3.2 隐式表征分歧度量与认知修正

当最新的输入特征 Q_t (传统意义上的 Query) 涌入网络时，DAM 并不与过去的每个历史 Token 进行点积比对，而是直接将其与当前的“动态思维点 $\mathcal{M}_t$ ”进行宏观对齐。在此过程中，分歧度的概念被引入到信息的调制中。

我们将当前步的激活特征 $\phi(Q_t)$ 定义为**隐式分歧度量门控** (Implicit Divergence Gating)：

$$\phi(Q_t) = \text{ELU}(Q_t) + 1.0 \quad (25)$$

在信息加工的视角下， $\phi(Q_t)$ 的各个独立特征通道分别衡量了新进信息与模型既有认知基底在该通道上的**冲突与不匹配程度**。最终的输出通过两者的哈达玛积 (Hadamard Product) 进行显式调制，并在最后施加层归一化 (LayerNorm) 以稳定训练过程中的数值分布：

$$\text{Output}_t = \text{LayerNorm}(\phi(Q_t) \odot \mathcal{M}_t) = \text{LayerNorm}\left(\phi(Q_t) \odot \frac{\text{kv_cumsum}_t}{\text{den_cumsum}_t}\right) \quad (26)$$

这一公式在认知科学上具备自洽的物理图景：

- **低分歧通道 (契合区)**：当新输入的某些特征通道与既有思维点的对应通道高度契合时， $\phi(Q_t)$ 的该通道值趋近于 1.0 (ELU 在匹配特征通道上接近零，加上 1.0 的偏置后约为 1.0)。其结果是，模型在这些通道上以基线强度维持了对历史记忆的**稳定访问**，不会引发剧烈的认知修正。这在功能上等价于人脑在熟悉情境中保持**稳定模式匹配**的认知状态。
- **高分歧通道 (冲突区)**：当新输入带来了打破常规模式的、高信息量的新特征时， $\phi(Q_t)$ 的对应通道值显著大于 1.0。这些增大的分歧度作为多通道门控，选择性地放大历史思维点中与该冲突强相关的记忆表征，从而在输出端引发了剧烈的“**认知修正信号**”。

这一机制将传统注意力中基于相似度的“信息检索”范式升级为基于分歧度的“**认知冲突检测与修正**”范式。其根本优势在于：模型不再是简单地“回忆相关的历史信息”，而是精确地“**识别需要修正的地方**，然后有针对性地**从历史中提取修正所需的线索**”。

3.3.3 层归一化与数值稳定性

DAM 在数值稳定性方面采取了三项基础保障措施，以确保在线性累加范式下的训练稳定性。

激活函数的选择——ELU+1.0。 $\phi(\cdot) = \text{ELU}(\cdot) + 1.0$ 的选择具有以下考虑：ELU 在正数区保持恒等映射 ($\text{ELU}(x) = x, x > 0$)，在负数区以指数形式平滑衰减至 -1 ，保证了输出在 $(-1, \infty)$ 区间。加上 1.0 的偏置后， $\phi(K)$ 的值域为 $(0, \infty)$ ，确保了下界严格大于零——这是分母 $\sum \phi(K)$ 保持非零的必要条件。相较于纯 ReLU (负值区硬截断为零导致信息丢失)，ELU 在负数区保留了梯度流动，有利于训练稳定性。

层归一化 (Layer Normalization)。DAM 在前向传播的最终输出上施加层归一化：

$$\text{Output}_t = \text{LayerNorm}\left(\phi(Q_t) \odot \frac{\text{kv_cumsum}_t}{\text{den_cumsum}_t}\right) \quad (27)$$

LayerNorm 将输出在每个特征维度上重新归一化为零均值、单位方差。这一操作具有三重功能：(1) 消除 ELU 正数区线性增长在深层传播中累积的数值漂移；(2) 为下游 Transformer 层提供稳定、规整的输入分布；(3) 使 DAM 对学习率和初始化策略的选择更具鲁棒性。LayerNorm 已被证明是 Transformer 架构中不可或缺的组件 [1]，DAM 将其直接纳入注意力计算的核心流程，而非像标准 Transformer 那样仅置于残差连接之后。

防零策略。在分母 `den_cumsum` 的计算中加入小常数 $\epsilon = 10^{-5}$ ，防止在序列起始处或所有 $\phi(K)$ 通道均为极小时的除零错误。这是线性注意力方法的通用做法，在实际训练中未见数值不稳定问题。

DAM PyTorch 参考实现：

```
def DAM(self, Q, K, V, is_causal=True, past_key_value=None, use_cache=False):
    b, h, n, d = Q.shape
    m = K.shape[2]
    phi_Q = F.elu(Q) + 1.0
    phi_K = F.elu(K) + 1.0
    eps = 1e-5

    if is_causal:
        if past_key_value is None:
            # Prefill 阶段
            assert n == m, "Causal mask requires..."
            kv_prod = phi_K * V
            kv_cumsum = torch.cumsum(kv_prod, dim=2)
            den_cumsum = torch.cumsum(phi_K, dim=2) + eps
            raw_ratio = kv_cumsum / den_cumsum
            output = phi_Q * raw_ratio
            output = F.layer_norm(output, (d,))
            current_total_len = m
            if use_cache:
                last_kv = kv_cumsum[:, :, -1:, :]
                last_den = den_cumsum[:, :, -1:, :]
        else:
            # Decode 阶段
            prev_kv = past_key_value["kv_sum"]
            prev_den = past_key_value["den_sum"]
            past_len = past_key_value["seq_len"]
            kv_cumsum = prev_kv + (phi_K * V)
            den_cumsum = prev_den + phi_K
            output = phi_Q * (kv_cumsum / (den_cumsum + eps))
            output = F.layer_norm(output, (d,))
            current_total_len = past_len + m
            if use_cache:
                last_kv = kv_cumsum
                last_den = den_cumsum

    if use_cache:
        next_past_key_value = {
            "kv_sum": last_kv,
            "den_sum": last_den,
```

```

        "seq_len": current_total_len
    }
    else:
        next_past_key_value = None

    else:
        kv_sum = (phi_K * V).sum(dim=2, keepdim=True)
        den_sum = phi_K.sum(dim=2, keepdim=True) + eps
        output = phi_Q * (kv_sum / den_sum)
        output = F.layer_norm(output, (d,))
        next_past_key_value = None

    return output, next_past_key_value

```

3.3.4 DAM 架构流程图

DAM 的完整计算流程图如图4所示：




图 4 DAM 与标准注意力（SDPA）计算流程图对比

3.3.5 复杂度对比与理论分析

定理 3.4 (DAM 的复杂度). 分歧聚合机制 DAM 的单层时间复杂度为 $O(nd)$, 推理显存占用为 $O(d)$ (即与序列长度 n 无关的恒定存储——仅需维护 `kv_cumsum` 和 `den_cumsum` 两个 d 维张量, 不会随生成步数增长)。

证明. 在 DAM 的前向传播中, 关键计算步骤包括:

1. 激活函数 $\phi(Q)$ 和 $\phi(K)$: 各 $O(nd)$
2. $\phi(K) \cdot V$ 的逐元素乘法和随后的累加 (cumsum 或 sum): $O(nd)$
3. 分母 $\phi(K)$ 的累加: $O(nd)$
4. 除法: $O(nd)$
5. 哈达玛积: $O(nd)$

所有步骤的复杂度均为 $O(nd)$, 无任何 $O(n^2)$ 项。对于推理缓存, 仅需存储最后的 `kv_cumsum` 和 `den_cumsum` 两个形状为 $b \times h \times 1 \times d$ 的张量, 其大小与序列长度 n 完全无关, 即 $O(d)$ ——不随 n 增长。相比之下, 标准注意力的 KV 缓存为 $O(nd)$ 。□

在第 2.2 节已对 DAM 与标准注意力及主要替代方案 (线性注意力、Mamba、RWKV 等) 进行了全面的复杂度对比, 此处不再赘述。DAM 最显著的优势在于推理显存与序列长度完全解耦: 无论输入序列是 1K、32K 还是 128K Token, DAM 仅需维护两个 d 维累积向量, 缓存大小始终保持不变, 且核心计算无需矩阵乘法, 全部由逐元素运算完成, 而标准注意力的 KV 缓存却随序列长度线性增长。

4 实验结果

4.1 DATP 持续学习实验

4.1.1 实验设置

为验证 DATP 在持续学习场景下的有效性, 我们在五个标准回归数据集上进行了系统的实验评估。数据集均来自 OpenML 平台, 覆盖了不同规模、不同领域的回归任务:

- **kin8nm** (OpenML ID: 189): 运动学数据集, 8 维输入, 预测机器人末端执行器的前向运动学。
- **house_16h** (OpenML ID: 574): 房价预测数据集, 16 维输入特征。
- **year_prediction_msds** (OpenML ID: 44040): 音乐年代预测数据集, 基于音频特征预测歌曲发行年份。
- **diamonds** (OpenML ID: 42225): 钻石价格预测数据集, 基于钻石的物理属性预测价格。
- **delays_housing** (OpenML ID: 42571): 住房相关延迟预测数据集。

实验配置:

- 基座网络: 2 层 MLP 特征提取器 (输入 $\rightarrow 64 \rightarrow 32$) + 线性回归头 ($32 \rightarrow 1$)
- 审判官网络: 2 层 MLP (输入 $\rightarrow 32 \rightarrow 1$ + Sigmoid)

- 训练/演化/测试划分：50% / 25% / 25%（训练集仅用于基座和审判官的离线预训练，演化集用于 DATP 的在线交互学习，测试集仅用于最终评估）
- 随机种子：42、100、2026（三次独立运行）
- 超参数： $\tau_{\text{error}} = 0.55$, $\tau_{\text{dist}} = 1.5$, $K_{\text{max}} = 150$ （全演化） / $K_{\text{max}} = 1000$ （无演化）
- 硬件：1 张 NVIDIA RTX 3090

我们比较了三种设定：

1. **Base**：仅使用冻结的基座网络进行预测（相当于传统深度学习模型的部署模式）。
2. **DATP (No-Evolution)**：启用思维点的创建和修正，但关闭聚合和遗忘机制。
3. **DATP (Full-Evolution)**：启用完整的 DATP 机制，包括思维点创建、修正、空间聚合和生物遗忘。

4.1.2 实验结果

表 3 DATP 在五个标准回归数据集上的持续学习实验结果（均值 $\pm$ 标准差）

数据集	Base R^2	No-Evo R^2	Full-Evo R^2	Nodes (No-Evo)	Nodes (Full-Evo)
kin8nm	0.8438 ± 0.0071	0.8447 ± 0.0072	0.8435 ± 0.0070	12.0 ± 4.4	3.0 ± 1.7
house_16h	0.4473 ± 0.1531	0.4494 ± 0.1461	0.4481 ± 0.1514	24.0 ± 4.4	3.3 ± 0.6
year_prediction_msd	0.9578 ± 0.0112	0.9580 ± 0.0110	0.9579 ± 0.0111	4.0 ± 1.0	2.3 ± 0.6
diamonds	0.9584 ± 0.0043	0.9587 ± 0.0042	0.9585 ± 0.0044	3.0 ± 1.0	2.3 ± 0.6
delays_housing	0.3050 ± 0.1095	0.3051 ± 0.1095	0.3051 ± 0.1094	7.3 ± 5.5	3.3 ± 2.1

4.1.3 结果分析

从表3可以得出以下关键观察：

(1) 性能保持稳定。在全部五个数据集上，Base、No-Evolution 和 Full-Evolution 三种设定的 R^2 得分差异均在统计误差范围之内（最大差异不超过 0.003）。这一结果表明，DATP 的思维点机制在引入在线持续学习能力的同时，**不损害基座模型原有的预测性能**。对于实际部署而言，这是一个至关重要的安全特性——模型的自我学习不会以性能退化为代价。

(2) 思维点数量大幅压缩。Full-Evolution 模式下的思维点数量相比 No-Evolution 模式在不同数据集上分别压缩了 75.0%（kin8nm, 12.0 $\rightarrow$ 3.0）、86.3%（house_16h, 24.0 $\rightarrow$ 3.3）、42.5%（year_prediction_msd, 4.0 $\rightarrow$ 2.3）、23.3%（diamonds, 3.0 $\rightarrow$ 2.3）和 54.8%（delays_housing, 7.3 $\rightarrow$ 3.3），按总数加权计算平均压缩比约为 72%。这一显著压缩来源于聚合机制将相似思维点融合为高泛化性节点以及遗忘机制自动清除低频噪声点的协同作用。思维点数量的减少直接意味着更小的内存占用和更快的思维点匹配速度。

(3) 推理延迟极低。全演化模式下的每样本推理延迟在 0.08–0.63 毫秒之间，即使在最复杂的 house_16h 数据集上也仅需 0.63 毫秒。这一极低的延迟归功于思维点

池的小规模（平均仅 2–3 个活跃思维点）以及欧氏距离匹配的 $O(Kd)$ 计算的高效性。在 RTX 3090 GPU 上，这一延迟水平完全满足实时推理的性能要求。

(4) 数据集难度与思维点需求正相关。 house_16h 数据集（房价预测， R^2 仅 0.45）需要最多的思维点（3.3 个），而 diamonds 数据集（钻石价格预测， R^2 达 0.96）仅需 2.3 个思维点。这表明 DATP 的思维点创建数量自适应地反映了任务的内在难度——任务越复杂、基座模型的预测能力越有限，思维点池需要维护越多的局部专家来弥补知识缺口。

4.2 DAM 语言建模实验

4.2.1 实验设置

为验证 DAM 在序列建模任务中的有效性，我们在 WikiText-103 语言建模基准数据集 [29] 上进行了预训练实验，并与标准的缩放点积注意力（SDPA）进行了对比。

实验配置：

- 词汇表大小：8000
- 注意力头数：8
- 前馈网络维度：2048
- 层数：8
- 学习率： $5e-4$
- 训练轮数：6
- 序列长度：256 / 1024 / 3500
- 硬件：1 张 NVIDIA RTX 3090

4.2.2 实验结果

表 4 DAM 与标准注意力在 WikiText-103 上的语言建模困惑度对比

架构	参数量	d_{model}	seq_len	验证集困惑度 (PPL)↓
SDPA	56MB	768	256	18.59
SDPA	56MB	768	1024	15.98
SDPA	84MB	1024	256	17.81
SDPA	84MB	1024	1024	15.94
SDPA	84MB	1024	3500	17.80
DAM	56MB	768	256	21.66
DAM	56MB	768	1024	22.21
DAM	84MB	1024	256	20.57
DAM	84MB	1024	1024	20.69
DAM	84MB	1024	3500	21.88

4.2.3 结果分析

从表4可以得出以下观察：

(1) **DAM 的困惑度在可接受范围内。**在 84MB 参数量、1024 序列长度的配置下，DAM 达到 20.69 的困惑度，相比同配置下的标准注意力（15.94 PPL）有约 4.75 的差距。这一差距需要放在上下文中理解：DAM 以 $O(nd)$ 的线性计算复杂度和与序列长度 n 无关的 $O(d)$ 显存占用为代价，换取了语言建模能力的轻微下降。对于长序列推理和资源受限场景而言，这一性能-效率的权衡是积极且合理的。

(2) **序列长度增加时 DAM 的 PPL 增长较为平缓。**当序列长度从 256 增加到 1024 再到 3500，标准注意力的 PPL 从 17.81 下降到 15.94 再上升到 17.80（呈 U 型曲线），而 DAM 的 PPL 从 20.57 到 20.69 再到 21.88（呈单调缓慢上升）。值得注意的是，从 1024 到 3500 序列长度，标准注意力的 PPL 增加了 1.86（从 15.94 到 17.80），而 DAM 仅增加了 1.19（从 20.69 到 21.88），DAM 在长序列上的困惑度增长幅度反而小于标准注意力，显示了 DAM 在长序列场景下良好的稳定性。

(3) **DAM 在更长序列上的优势将逐步显现。**尽管在短序列上 DAM 的困惑度不如标准注意力，但随着序列长度的增长（特别是在 32K、128K 等极端长度下），标准注意力的 $O(n^2)$ 计算和 $O(nd)$ 存储将迅速变得不可行，而 DAM 的 $O(nd)$ 和与序列长度无关的 $O(d)$ 存储特性使其天然适应于长序列场景。

5 讨论

5.1 思维点与分歧度范式的理论意义

本文提出的思维点与分歧度框架，其最根本的理论贡献在于**将模型持续学习问题从参数空间的优化问题转化为非参数空间的动态组织问题**。传统持续学习方法（EWC、SI、经验回放等）都在参数更新的框架内寻求遗忘与学习的平衡，本质上是对同一参数空间的零和博弈——新知识的学习必须以旧知识的某种程度的牺牲为代价。DATP 的方法论避免了这一零和困境：基座参数空间保持完全不变（消除遗忘），而所有新的学习都发生在一个独立的、专门为此设计的非参数思维点空间内。

从更宏观的视角看，这一思路可以被视为对“学习”这一概念本身的重新界定。在传统的机器学习范式中，“学习”等价于“修改模型的参数”。而在 DATP 的框架下，“学习”被重新定义为“在参数空间之外构建和演化一个独立的知识补丁系统”。这一重新界定使得学习不再必然地与遗忘相伴，从而为持续学习问题提供了一个根本性的解决框架。

5.2 DAM 与标准注意力的本质区别

DAM 与传统注意力机制的本质区别可以总结为公式层面的以下对比：

在 DAM 公式中，我们将历史时序特征压缩、凝聚为统一的动态思维点 $\frac{kv_cumsum}{den_cumsum}$ 。与此同时， ϕ_Q 被定义为当前输入表征与该思维质心之间的隐式分歧度度量门控（Implicit Divergence Gating）。通过两者的乘性交互（Element-wise Modulation），网络能够根据新旧信息的冲突与分歧程度，动态调节历史记忆的释放与当前表征的修正，从而实现了长文本场景下高效、鲁棒的线性记忆追踪。

这与传统注意力通过 softmax 对每个历史 Token 分配独立权重的范式有着根本性的区别。

5.3 局限性分析

尽管本文的方法在理论和实验上展现了有前景的结果，但仍存在以下局限性需要诚实面对：

(1) **DAM 在短序列上的困惑度略逊于标准注意力，但在长序列上展现了更优的稳定性。**在 WikiText-103 上 1024 序列长度下，DAM 的 20.69 PPL 与标准注意力的 15.94 PPL 之间仍存在约 4.75 的差距。这一差距的来源可能是 ELU+1 核函数无法完美模拟 softmax 的尖锐归一化特性——softmax 在相关 Token 与不相关 Token 之间能够产生指数级的权重差异，而 ELU+1 的线性正数区门控更为平滑，通道间的区分度不及 softmax 的指数级对比度。然而，值得关注的是，当序列长度从 1024 增加到 3500 时，标准注意力的 PPL 上升了 1.86（从 15.94 到 17.80），而 DAM 仅上升了 1.19

(从 20.69 到 21.88)。DAM 在长序列上的困惑度增长幅度小于标准注意力，这一结果表明 DAM 的凝聚思维点机制在长距离依赖建模中具有内在的稳定性优势，因为其信息压缩方式避免了标准注意力中大量无关 Token 造成的“信息稀释”效应。

(2) DATP 在大规模语言模型上的验证尚未完成。当前的 DATP 实验仅在 MLP 回归任务上进行了验证。在数十亿参数级别的 LLM 上应用 DATP 面临着可扩展性的挑战：审判官网络需要在 Transformer 的哪个层次预测错误？思维点的特征锚点应当取哪一层的隐状态？这些问题需要未来的工作来回答。

(3) 演化动力学的超参数需要手动调节。聚合阈值 $0.4 \cdot \tau_{\text{dist}}$ 、健康度衰减率 -0.15 和恢复速率 $+0.05$ 等参数目前基于经验设定。在分布差异较大的场景中，这些参数可能需要手动重新调校。未来的工作可以探索自适应的元学习方法来动态调节这些演化参数。

(4) 理论基础有待进一步夯实。尽管本文从认知科学和线性代数的角度为思维点和分歧度提供了理论论证，但对于“在线创建思维点为何不会导致发散”以及“聚合-遗忘过程为何能收敛到稳定状态”等问题，尚缺乏严格的数学证明（如收敛性定理和泛化界分析）。

(5) 本工作目前处于理论实践阶段。DATP 和 DAM 尚处于早期探索阶段，距离大规模工业部署仍有距离。当前实验均在小规模数据集上完成，方法在更大规模和更多类型任务上的适用边界还需要更多的实验来界定。

本文的方法可以视为开创了一个新的研究子领域：**非参数化的自组织持续学习**。在这个框架下，模型的知识增长来自于一个与参数空间解耦的、自适应演化的局部专家池，而非参数的梯度更新。这一框架的理论潜力远未被充分挖掘。

6 结论与展望

6.1 主要结论

本文从深度学习模型面临的两大核心瓶颈——无法自我持续学习和自注意力的平方级复杂度——出发，提出了以“思维点”和“分歧度”为核心概念的分聚思维点网络（DATP）和分歧聚合机制（DAM）。主要结论如下：

- 概念层面：**思维点和分歧度构成了一个自洽的认知闭环系统。思维点作为压缩的局部知识单元，在非参数空间中承载了模型的纠错经验和认知补丁；分歧度作为新信息与既有认知之间冲突程度的度量，驱动着思维点的匹配、创建和演化。这一概念体系为解决模型持续学习问题提供了新的理论语言。
- 方法层面：**DATP 通过通用基座网络、解耦审判官和动态思维点池的三元架构，实现了模型在不修改基座参数前提下的流式持续自我学习。空间聚合机制将散落知识凝聚为高频泛化区域，生物遗忘机制自动清除噪声和过时知识，保证了系统的有

界性和鲁棒性。

3. **效率层面**：DAM 以分歧度替代相似度作为信息交互的核心度量，完全摒弃矩阵乘法，通过纯逐元素运算（累加、除法和哈达玛积）实现线性记忆锚定和隐式分歧度门控，达成了 $O(nd)$ 的时间复杂度和与序列长度 n 无关的 $O(d)$ 推理显存（仅需维护两个 d 维累积向量），使其天然适用于长文本和资源受限场景。
4. **实验层面**：在五个回归数据集上的实验证明了 DATP 在保持预测性能稳定的同时，通过演化动力学将思维点数量压缩约 75%，推理延迟控制在每样本亚毫秒级别。在 WikiText-103 上的预训练实验证明了 DAM 以 84MB 参数量达到 20.69 困惑度的语言建模能力，与同参数规模的线性复杂度方法处于竞争区间。

6.2 未来展望

本文的工作开启了多个值得深入探索的研究方向：

1. **大规模语言模型上的 DATP 部署**。将 DATP 框架从 MLP 回归任务扩展到数十亿参数的 Transformer-based LLM 是最高优先级的研究方向。关键挑战包括：在 Transformer 的多层架构中确定思维点锚点的最佳提取位置（中间层？最后层？多层融合？）；设计适用于自回归生成任务的审判官机制；处理离散 Token 输出空间中的残差修正问题。
2. **DAM 的进一步优化**。探索使用更丰富的核函数（如可学习的径向基函数或门控线性单元）来进一步增强 DAM 的表达能力，以缩小与 softmax 注意力在语言建模能力上的差距。研究 DAM 中的 LayerNorm 配置策略，以及 DAM 在视觉、语音等多模态场景中的适用性。
3. **演化动力学的理论分析**。对思维点池的长期行为进行严格的数学建模——证明聚合-遗忘过程在何种条件下收敛到稳定分布，推导思维点数量的上界和期望值，分析泛化误差与思维点池规模之间的理论关系。
4. **认知科学启发的进一步拓展**。将更多人类认知机制——如睡眠记忆巩固、情绪调节学习、选择性注意——映射到 DATP 的演化动力学框架中，探索更丰富的思维点生命周期管理策略。
5. **DATP 在实际应用中的部署验证**。作为目前仍处于理论实践阶段的框架，DATP 需要通过更多实际场景的验证来证明其方法论的普适性和稳定性，包括但不限于在线推荐系统、实时异常检测和自适应对话系统等。

参考文献

- [1] Vaswani A, Shazeer N, Parmar N, et al. Attention is all you need. *Advances in Neural Information Processing Systems*, 2017, 30.
- [2] Shazeer N. Fast transformer decoding: One write-head is all you need. *arXiv preprint arXiv:1911.02150*, 2019.
- [3] Ainslie J, Lee-Thorp J, de Jong M, et al. GQA: Training generalized multi-query transformer models from multi-head checkpoints. *Proceedings of EMNLP 2023*, 2023.
- [4] DeepSeek-AI. DeepSeek-V2: A strong, economical, and efficient mixture-of-experts language model. *arXiv preprint arXiv:2405.04434*, 2024.
- [5] Katharopoulos A, Vyas A, Pappas N, et al. Transformers are RNNs: Fast autoregressive transformers with linear attention. *Proceedings of ICML 2020*, 2020.
- [6] Choromanski K, Likhoshesterov V, Dohan D, et al. Rethinking attention with performers. *Proceedings of ICLR 2021*, 2021.
- [7] Gu A, Goel K, Ré C. Efficiently modeling long sequences with structured state spaces. *Proceedings of ICLR 2022*, 2022.
- [8] Gu A, Dao T. Mamba: Linear-time sequence modeling with selective state spaces. *arXiv preprint arXiv:2312.00752*, 2023.
- [9] Dao T, Gu A. Transformers are SSMS: Generalized models and efficient algorithms through structured state space duality. *Proceedings of ICML 2024*, 2024.
- [10] Peng B, Alcaide E, Anthony Q, et al. RWKV: Reinventing RNNs for the transformer era. *Findings of EMNLP 2023*, 2023.
- [11] Sun Y, Li X, Dalal K, et al. Learning to (learn at test time): RNNs with expressive hidden states. *arXiv preprint arXiv:2407.04620*, 2024.
- [12] Goodfellow I, Pouget-Abadie J, Mirza M, et al. Generative adversarial nets. *Advances in Neural Information Processing Systems*, 2014, 27.
- [13] Shazeer N, Mirhoseini A, Maziarz K, et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer. *Proceedings of ICLR 2017*, 2017.

- [14] Fedus W, Zoph B, Shazeer N. Switch transformers: Scaling to trillion parameter models with simple and efficient sparsity. *Journal of Machine Learning Research*, 2022, 23(120): 1–39.
- [15] Sutton R S, Barto A G. *Reinforcement learning: An introduction* (2nd ed.). MIT Press, 2018.
- [16] Kahneman D. *Thinking, fast and slow*. Farrar, Straus and Giroux, 2011.
- [17] Stanovich K E, West R F. Individual differences in reasoning: Implications for the rationality debate? *Behavioral and Brain Sciences*, 2000, 23(5): 645–665.
- [18] Nye M, Andreassen A J, Gur-Ari G, et al. Show your work: Scratchpads for intermediate computation with language models. *arXiv preprint arXiv:2112.00114*, 2021.
- [19] Wang L, Zhang X, Su H, et al. A comprehensive survey of continual learning: Theory, method and application. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 2024, 46(8): 5362–5383.
- [20] Kirkpatrick J, Pascanu R, Rabinowitz N, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 2017, 114(13): 3521–3526.
- [21] Rusu A A, Rabinowitz N C, Desjardins G, et al. Progressive neural networks. *arXiv preprint arXiv:1606.04671*, 2016.
- [22] Zenke F, Poole B, Ganguli S. Continual learning through synaptic intelligence. *Proceedings of the 34th International Conference on Machine Learning (ICML)*, 2017.
- [23] Zheng J, Qiu S, Shi C, et al. Towards lifelong learning of large language models: A survey. *arXiv preprint arXiv:2406.06391*, 2024.
- [24] Yang S, Wang B, Shen Y, et al. Gated linear attention transformers with hardware-efficient training. *Proceedings of ICML 2024*, 2024.
- [25] Arora S, Eyuboglu S, Timalsina A, et al. Zoology: Measuring and improving recall in efficient language models. *Proceedings of ICLR 2024*, 2024.
- [26] Zhang M, Bhatia K, Kumbhari K. The hedgehog & the porcupine: Expressive linear attentions with softmax mimicry. *Proceedings of ICLR 2024*, 2024.

- [27] Jacobs R A, Jordan M I, Nowlan S J, et al. Adaptive mixtures of local experts. *Neural Computation*, 1991, 3(1): 79–87.
- [28] Mallya A, Lazebnik S. PackNet: Adding multiple tasks to a single network by iterative pruning. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2018.
- [29] Merity S, Xiong C, Bradbury J, et al. Pointer sentinel mixture models. *Proceedings of ICLR 2017*, 2017.
- [30] Sun Y, Dong L, Huang S, et al. Retentive network: A successor to transformer for large language models. *arXiv:2307.08621*, 2023.
- [31] Lieber O, Lenz B, Bata H, et al. Jamba: A hybrid transformer-Mamba language model. *arXiv:2403.19887*, 2024.
- [32] Teyler T J, DiScenna P. The hippocampal memory indexing theory. *Behavioral Neuroscience*, 1986, 100(2): 147–154.
- [33] Olshausen B A, Field D J. Emergence of simple-cell receptive field properties by learning a sparse code for natural images. *Nature*, 1996, 381(6583): 607–609.
- [34] Quiroga R Q, Reddy L, Kreiman G, et al. Invariant visual representation by single neurons in the human brain. *Nature*, 2005, 435(7045): 1102–1107.
- [35] Rao R P, Ballard D H. Predictive coding in the visual cortex: A functional interpretation of some extra-classical receptive-field effects. *Nature Neuroscience*, 1999, 2(1): 79–87.
- [36] Friston K. A theory of cortical responses. *Philosophical Transactions of the Royal Society B: Biological Sciences*, 2005, 360(1456): 815–836.
- [37] Nelson T O, Narens L. Metamemory: A theoretical framework and new findings. *Psychology of Learning and Motivation*, 1990, 26: 125–173.